

sycophancy - finetuning shift (pooled, layer 20)

