

sycophancy - finetuning shift (pooled, layer 19)

